


课程笔记

CS336 Lecture 12: 语言模型评估

Stanford CS336: Language Modeling from Scratch (Spring 2025)

讲师: Percy Liang 笔记: ZCode

2026-07-14



视频作者/频道: Stanford CS336

发布日期: 2025 Spring

视频时长: 81 分钟

视频链接: <https://www.youtube.com/watch?v=x-R5l2HsXqM>

Contents

1	评估为何如此困难	2
1.1	看起来简单，实则深邃	2
1.2	四种看模型好坏的视角	2
1.3	评估危机	5
1.4	评估为什么决定了模型怎么被造	5
2	评估的概念框架	6
2.1	没有唯一正确的评估	6
2.2	四步评估框架	7
3	Perplexity：最古老的语言模型指标	8
3.1	Perplexity 是什么	8
3.2	2010 年代的 perplexity 黄金期	9
3.3	GPT-1/2 改变了评估范式	10
3.4	数据污染与去污染	10
3.5	Perplexity 的局限：被回避的难题	11
4	知识型 Benchmark：MMLU 家族	13
4.1	MMLU 是什么	13
4.2	Few-shot 的方差陷阱	14
4.3	MMLU 的时代错位	15
4.4	MMLU-Pro 与更难的变体	16
5	开放生成与人类偏好	18
5.1	核心难题：开放生成怎么评	18
5.2	Chatbot Arena：众包偏好与 Elo	18
5.3	IFEval：指令遵循的可验证测试	19
5.4	AlpacaEval / WildBench：LLM-as-judge	20
6	Agent 与系统级评估	21
6.1	为什么需要 agent benchmark	21
6.2	隔离推理能力：ARC	22
7	安全评估	23
7.1	安全 benchmark 是什么	23
7.2	红队与越狱	23
7.3	预部署测试与监管	24
8	真实世界与评估的元问题	24
8.1	Benchmark 与现实脱节	24
8.2	污染检测与标注噪声	24
8.3	方法 vs 模型：评估对象的回归	25
8.4	竞赛式评估的启示	25
9	总结	26
9.1	核心论点	26
9.2	贯穿始终的主线	26
9.3	评估清单：动手前问自己	26
9.4	配套阅读	26

1 评估为何如此困难

1.1 看起来简单，实则深邃

Lecture 12 主题是评估 (evaluation)。Percy Liang 开宗明义：这是“看起来简单实则远非如此”的话题。机械地说，评估就是把一个固定好的模型拿来，对它提问“你有多好”——给一组 prompt，收集输出，算一个指标，取平均。




Figure 1: 论文中的 benchmark 分数：Llama 4 在 MMLU Pro / Math 500 / GPQA 等任务上的成绩¹

但真实情况远比这复杂。随便翻开一篇语言模型论文，你会看到一连串数字——MMLU、HumanEval、Codeforces、DROP、GSM8K、GPQA……大多数模型在大致相同的 benchmark 上评测，但又“不完全一样”。这些数字到底意味着什么？哪一个是对的“评测方式”？这就是本讲要厘清的核心问题。

1.2 四种看模型好坏的视角

Percy 在课堂上抛出了一组异质的“好坏信号源”，展示评估生态的碎片化：

¹视频画面时间区间：00:00:25 – 00:00:55。




Figure 2: HELM：把多种标准 benchmark 聚合在一起的统一评估平台²




Figure 3: Artificial Analysis：横轴价格、纵轴“智能指数”的 Pareto 前沿——不仅看能力，也看成本³

²视频画面时间区间：00:01:35 – 00:02:05。

³视频画面时间区间：00:02:05 – 00:02:35。




Figure 4: OpenRouter: 按人们实际调用各模型的 token 量排序——“好用与否”的隐式投票⁴

1. 论文里的 benchmark 表：每个实验室自报家门，挑自己想报的指标。
2. 聚合平台（HELM）：尽量把多任务、多维度标准化地摆在一起。
3. Pareto 前沿（Artificial Analysis）：能力与价格权衡，o3 很强但也很贵，别的模型可能“够好且便宜得多”。
4. 使用流量（OpenRouter）：模型好坏的最终证据，或许是人们是否真的在用。按 token 流量排序，OpenAI、Anthropic、Google 居前。
5. Chatbot Arena：互联网众包的成对偏好，转成 Elo 排名——后面会专门讨论它的问题。
6. “vibes”：X 上的零散案例（“看这个模型多强”），并非系统评测。

⁴视频画面时间区间：00:02:45 – 00:03:15。

1.3 评估危机




Figure 5: Karpathy 的判断：我们正处于“评估危机”——benchmark 被饱和或被博弈⁵

Percy 引用 Andrej Karpathy 的判断：当下存在评估危机（evaluation crisis）。曾经的金标准如 MMLU，其底层假设已被动摇——要么饱和（所有人都 90%+，无法区分），要么被博弈（goodhart's law: 一旦某个指标被当成目标优化，它就不再是好指标），要么介于二者之间。Chatbot Arena 也问题重重。

Goodhart 定律的评估版

当一个评测变成被追踪、被优化的目标，它就立刻失去作为“真理”的资格。模型开发者会盯着 leaderboard 做决策，于是 leaderboard 反过来塑造了模型——这正是评估为何是“未来走向的领先指标”。

Percy 强调本课的一个贯穿性主题：一切都 messy，评估也不例外。

1.4 评估为什么决定了模型怎么被造

评估不只是事后的“打分牌”。它深刻地反向塑造模型开发：前沿实验室追踪这些指标随时间的变化，试图让自己的数字上升；于是指标指导了开发决策。评估因而是一个领先指标（leading indicator），预示着技术往哪走。

⁵视频画面时间区间：00:03:25 – 00:03:55。

2 评估的概念框架

2.1 没有唯一正确的评估




Figure 6: 没有”一个真实评估”：评估取决于你想回答什么问题⁶

核心命题

不存在”那个唯一的评估”。评估的好坏，取决于它是否回答了你最初想问的问题。”我只是在评估一个模型”——这句话本身没有意义，因为脱离了目标，那个数字什么也不说明。

Percy 列举了四类典型的评估动机，每类背后是不同的”问题”：

谁在评估	想回答的问题	对应的评估
用户/采购方	Claude、Grok、Gemini、o3 哪个适合我的场景	任务特化、成本敏感
研究者	模型的原始能力？AI 是否在 进步	通用、与使用解耦
政策制定者 模型开发者	模型的收益与风险现状 这个干预有效吗？要不要保 留	全面、覆盖能力与安全 快速、可对比

⁶视频画面时间区间：00:06:25 – 00:06:55。

2.2 四步评估框架




Figure 7: 评估的统一框架：输入 → 调用模型 → 评估输出 → 解读结果⁷

Percy 给出一个简单的四步框架，每一步都藏着陷阱：

整体可抽象为一条从输入到分数的管线。设输入分布 Q 、模型 M_θ 、调用策略 π (few-shot/CoT/工具)、评分函数 s ，则评估就是对该管线的期望：

$$\text{Score}(M_\theta) = \mathbb{E}_{q \sim Q} [s(\pi(M_\theta, q), q)]$$

- q : 从输入分布 Q 采样的 prompt
- $\pi(M_\theta, q)$: 在策略 π 下、模型 M_θ 对 q 的调用与生成过程
- $s(\cdot, q)$: 针对题 q 的评分函数 (exact match、胜率、测试通过率……)
- 最终分数是这条管线在输入分布上的期望——每一环的偏差都会污染它

第一步——输入 (inputs)：prompt 从哪来？覆盖哪些用例？有没有“尾部”困难样本，还是全是 vanilla 简单题？更微妙的是，输入是否要适配模型。多轮对话里输入天然依赖模型；单轮也未必固定。红队 (red teaming) 里，为模型量身定制 prompt 才能高效触发罕见有害行为——但这又让跨模型比较变得困难。

输入适配的两难

适配输入 → 触发尾部事件更高效；但不适配 → 不同模型才可比。这是评估设计中无处不在的张力。

第二步——调用模型 (calling the LM)：零样本、少样本、思维链 (CoT)？是否允许工具调用 (计算器、代码执行、检索增强)？这些决策会引入巨大的方差。语言模型对 prompt 极其敏感，评估必须把这种敏感性纳入考量。

第三步——评估输出 (assessing outputs)：参考答案干净吗、无错吗？代码生成用 pass@1 还是 pass@10？成本是否被考虑？leaderboard 常把成本“边缘化”掉，于是你看不到第一名可能比第二名贵 10 倍。开放生成 (“写一个关于 Stanford 的故事”) 没有 ground truth，怎么评？

代码生成中的 pass@ k 定义为：从模型采样 n 个候选解，其中至少有一个通过测试的概率：

⁷视频画面时间区间：00:08:15 – 00:08:45。

$$\text{pass}@k = 1 - \frac{\binom{n-c}{k}}{\binom{n}{k}}$$

- n : 总采样数; c : 其中正确的个数; k : 允许选取的个数
- $\binom{n-c}{k}/\binom{n}{k}$: 在 n 中随机取 k 个全部取错的概率
- $\text{pass}@1$ 最严苛 (一次就要对), $\text{pass}@10$ 宽松得多——选不同的 k 会得到截然不同的“代码能力”结论

第四步——解读结果 (interpreting results): 拿到 91 分, 够用吗? 能上线吗? 是否真的学到了某种泛化? 这要求直面训练-测试重叠 (train-test overlap)。还有: 你评的到底是模型、是系统、还是方法? 研究论文的产出常是一个新方法, 模型只是它的载体——没有清晰对照, 评估就没意义。

评估对象的重重性

- 模型 (model): 开发者关心的对象, scaffolding 只是手段。
- 系统 (system): 用户关心的对象, 可能含多个模型 + 工具, 只看端到端效果。
- 方法 (method): 研究者关心的对象, 需要严格控制才能分离出方法的贡献。

混淆这三者, 是评估中最常见的概念错误。

3 Perplexity: 最古老的语言模型指标

3.1 Perplexity 是什么




Figure 8: Perplexity: 语言模型对测试集分配的概率 (对数似然的指数)⁸

语言模型本质上是一个 token 序列上的概率分布。Perplexity 衡量的是: 模型对某个数据集 (通常是验证集或测试集) 分配了多高的概率。形式化地, 给定长度为 L 的测试序列 $\mathbf{x} = (x_1, \dots, x_L)$, 模型参数为 θ :

⁸视频画面时间区间: 00:16:45 – 00:17:15。

$$\log p_{\theta}(\mathbf{x}) = \sum_{t=1}^L \log p_{\theta}(x_t | x_{<t})$$

- $p_{\theta}(x_t | x_{<t})$: 模型在给定前缀 $x_{<t}$ 时预测位置 t 的条件概率
- $\log p_{\theta}(\mathbf{x})$: 序列的对数似然，越大说明模型越“认可”这串数据

定义每个 token 的平均负对数似然，再取指数即为 perplexity:

$$\text{PPL}(\mathbf{x}) = \exp \left(-\frac{1}{L} \sum_{t=1}^L \log p_{\theta}(x_t | x_{<t}) \right)$$

- PPL: 困惑度，可理解为“模型在每个位置平均在多少个等概率词之间犹豫”
- $\text{PPL} = 1$ 意味完全确定；越大越困惑
- 它是自回归训练目标的直接延伸，因此预训练就是在最小化训练集的 perplexity

为什么用交叉熵的指数？

负对数似然 (NLL) 即交叉熵 $\mathcal{L}_{\text{CE}}$ 。取指数 $\exp(\mathcal{L}_{\text{CE}})$ 后，单位从“每 token 比特”变成“等效候选词数”，更直观—— $\text{PPL}=30$ 意味着模型像在 30 个等可能词里猜。

3.2 2010 年代的 perplexity 黄金期

95 Summary: lots of questions to think through when doing evaluation

97 `def perplexity():`

98 Recall: that a language model is a probability distribution $\mathbf{p}(\mathbf{x})$ over sequences of tokens.

99 Perplexity $(1/p(D))^{(1/|D|)}$ measures whether p assigns high probability to some dataset D .

100

101 In pre-training, you minimize perplexity on the training set.

102 The obvious thing is to measure perplexity on the test set.

103

104 Standard datasets: Penn Treebank (WSJ), WikiText-103 (Wikipedia), One Billion Word Benchmark (from machine translation WMT11 - EuroParl, UN, news)

105 Papers trained on a dataset (training split) and evaluated on the same dataset (test split)

106 Pure CNNs+LSTMs on the One Billion Word Benchmark (perplexity 51.3 -> 30.0) [Jozefowicz+ 2016]

GPT-2 trained on WebText (40GB text, websites linked from Reddit), zero-shot on standard datasets
This is out-of-distribution evaluation (but idea is that training covers a lot)

Language Models are Unsupervised Multitask Learners

	LAMBADA (PPL)	LAMBADA (ACC)	CBT-CN (ACC)	CBT-NE (ACC)	WikiText2 (PPL)	PTB (PPL)	enwik8 (BPP)	text8 (BPC)	WikiText103 (PPL)	1BW (PPL)
SOTA	99.8	59.23	85.7	82.3	39.14	46.54	0.99	1.08	37.50	75.20
117M	35.13	45.99	87.65	83.4	29.41	65.85	1.16	1.17	26.37	55.72
345M	15.60	55.48	92.35	87.1	22.76	47.33	1.01	1.06	26.37	55.72

Stanford

Figure 9: GPT-2: 在 WebText 上训练后，零样本跨域评测 Penn Treebank / WikiText / 1B Words⁹

2010 年代的语言建模研究就建立在一组标准数据集上: **Penn Treebank** (可追溯到 1990 年代)、**WikiText**、**1 Billion Word Benchmark** (源自机器翻译，多为政府公文与新闻)。研究者各取一个数据集，在指定训练 split 上训练，在测试 split 上报 perplexity。

Google 一篇标志性论文表明：只要架构设计得当并放大规模，perplexity 能从 51 大幅降到 30——这是断崖式的进步。Perplexity 作为一个 challenge problem，强力推动了语言建模研究。

⁹视频画面时间区间: 00:18:55 – 00:19:25。

小数据 vs 大数据的两套游戏

在小数据集上，人们担心过拟合；而在大数据集上，游戏变成“能不能把数据拟合进去”。这是 Percy 强调的范式分野。

3.3 GPT-1/2 改变了评估范式

GPT-2 在 40GB 网页文本（Reddit 外链）上训练，然后不微调、直接在 Penn Treebank、WikiText 等标准 benchmark 上评测。这是典型的分布外评估——训练分布是网页，评测分布是学术语料。但训练数据足够广，模型获得了强泛化。

结果是：在 Penn Treebank 等小数据集上，GPT-2 零样本就超越了专门在这些数据上训练的 SOTA；只在 1B Words 上仍略逊。这说明足够广的预训练可以“顺便”赢下狭义任务。Cross-entropy / perplexity 与下游表现的弱相关性也由此埋下伏笔。

Perplexity 与下游能力的关系并不稳健

Tatsu 上一讲展示的图表明：perplexity 与下游任务的相关性忽高忽低。只有当跨多个 scale 纵观时，perplexity 才“全局上”对应一切在变好——强模型在大多数事上都强，1B 小模型在大多数事上都弱。但局部、单点上，perplexity 下降未必带来你关心的那个能力的提升。

3.4 数据污染与去污染

Standard datasets: Penn Treebank (WSJ), WikiText-103 (Wikipedia), One Billion Word Benchmark (from machine translation WMT11 - EuroParl, UN, news)

Papers trained on a dataset (training split) and evaluated on the same dataset (test split)

Pure CNNs+LSTMs on the One Billion Word Benchmark (perplexity 51.3 -> 30.0) [Jozefowicz+ 2016]

GPT-2 trained on WebText (40GB text, websites linked from Reddit), zero-shot on standard datasets

This is out-of-distribution evaluation (but idea is that training covers a lot)

	LAMBADA (PPL)	LAMBADA (ACC)	CBT-CN (ACC)	CBT-NE (ACC)	WikiText2 (PPL)	PTB (PPL)	enwik8 (BPB)	text8 (BPC)	WikiText103 (PPL)	1BW (PPL)
SOTA	99.8	59.23	85.7	82.3	39.14	46.54	0.99	1.08	18.3	21.8
117M	35.13	45.99	87.65	83.4	29.41	65.85	1.16	1.17	37.50	75.20
345M	15.60	55.48	92.35	87.1	22.76	47.33	1.01	1.06	26.37	55.72
762M	10.87	60.12	93.45	88.0	19.93	40.31	0.97	1.02	22.05	44.575
1542M	8.63	63.24	93.30	89.05	18.34	35.76	0.93	0.98	17.48	42.16

Works better on small datasets (transfer is helpful), but not larger datasets (1BW)

Since GPT-2 and GPT-3, language modeling papers have shifted more towards downstream task accuracy. But reasons why perplexity is still useful:

- Smoother than downstream task accuracy (for fitting scaling laws)
- Is universal (why we use it for training) whereas task accuracy might miss some nuances
- Note: can measure conditional perplexity on downstream task too (used for scaling laws) [Bhagla+ 2024]

Stanford

Figure 10: 数据污染（contamination）：测试集泄入训练数据，导致指标虚高¹⁰

污染（contamination）是 perplexity 评估的头号威胁：如果测试集本身就是训练数据的一部分，模型只是“背答案”，perplexity 虚低，但泛化能力为零。标准做法是去污染（decontamination）：把测试集与训练集做比对，移除任何重叠文档。

保守去污染的原则

与其纠结“是否真的训过”，不如直接保守地剔除一切可疑重叠。网页文本浩如烟海——即便少训了一些，模型仍能学好。若不剔，perplexity 数字毫无意义。

¹⁰ 视频画面时间区间：00:21:30 – 00:23:00。

污染的威胁可以用信息论刻画。设真实数据分布为 T 、模型分布为 P 。理想情况下 $P \rightarrow T$ ，交叉熵逼近熵的下界：

$$H(T, P) = H(T) + D_{\text{KL}}(T \| P) \geq H(T)$$

- $H(T, P)$ ：交叉熵，即我们最小化的训练目标
- $H(T)$ ：真实分布的熵，是 perplexity 的理论下界
- $D_{\text{KL}}(T \| P)$ ：KL 散度，衡量模型与真分布的偏离，非负

若测试集 T_{test} 被污染进训练集，模型对它的概率被人为抬高，交叉熵低于 $H(T)$ ——这从数学上就不可能来自真实的泛化，只能是记忆。于是污染让指标违反信息论下界，是可探测的异常。

3.5 Perplexity 的局限：被回避的难题

	30.1A	39.6	39.25	63.7	64.3	39.14	40.34	0.99	1.06	16.3	21.8
117M	35.13	45.99	87.65	83.4	29.41	65.85	1.16	1.17	37.50	75.20	
345M	15.60	55.48	92.35	87.1	22.76	47.33	1.01	1.06	26.37	55.72	
762M	10.87	60.12	93.45	88.0	19.93	40.31	0.97	1.02	22.05	44.575	
1542M	8.63	63.24	93.30	89.05	18.34	35.76	0.93	0.98	17.48	42.16	

111 Works better on small datasets (transfer is helpful), but not larger datasets (1BW)

112

113 Since GPT-2 and GPT-3, language modeling papers have shifted more towards downstream task accuracy.

114 But reasons why perplexity is still useful:

115

- Smoother than downstream task accuracy (for fitting scaling laws)
- Is universal (why we use it for training) whereas task accuracy might miss some nuances
- Note: can measure conditional perplexity on downstream task too (used for scaling laws) [Bhagia+ 2024]

Warning (if you're running a leaderboard): evaluator needs to trust the language model
For task accuracy, can just take output generated from a blackbox model and compute the desired metrics
For perplexity, need LM to generate probabilities and trust that they sum to 1 (even worse with UNKs back in the day)

The perplexity maximalist view:

- Your true distribution is t , model is p
- Best possible perplexity is $H(t)$ obtained iff $p = t$
- If have t , then solve all the tasks
- So by pushing down on perplexity, will eventually reach AGI

Stanford

Figure 11: Scaling laws 与 perplexity：长程、多尺度上 perplexity 才与能力全局对应¹¹

Percy 介绍了一类“perplexity 极简主义者 (perplexity maximalist)”的立场：与其精心设计下游任务，不如只优化 $D_{\text{KL}}(T \| P)$ ——即最大化似然。理由是它信息量最大。设 P 为模型分布、 T 为真实分布，最大似然等价于最小化交叉熵：

$$\min_{\theta} H(T, P_{\theta}) = \min_{\theta} \mathbb{E}_{\mathbf{x} \sim T} [-\log P_{\theta}(\mathbf{x})]$$

- T ：真实数据分布
- P_{θ} ：参数 θ 下的模型分布
- $H(T, P_{\theta})$ ：交叉熵，最大似然训练的直接目标

但反方指出：这可能不是最有效的路径。把概率质量压在不该出现的地方（噪声、低质 token）纯属浪费算力。更糟的是，perplexity 对很多真正重要的能力不敏感——比如指令遵循、安全性、长程推理。

事实上，perplexity 与下游能力 C 之间只存在弱、带噪声的相关，可用一个带噪声的回归刻画：

$$C \approx \alpha \cdot (-\log \text{PPL}) + \varepsilon, \quad \text{Var}[\varepsilon] \text{ 较大}$$

¹¹视频画面时间区间：00:24:05 – 00:24:35。

- C : 某项下游能力 (如 MMLU 准确率)
- $-\log \text{PPL}$: perplexity 的对数 (越高模型越强)
- α : 整体正相关斜率, 仅在跨多个 scale 纵观时才稳定为正
- ε : 残差噪声, 单点上方差大——这就是“perplexity 下降未必带来该能力提升”的数学表达

Perplexity 的三大盲区

1. 对指令/对齐不敏感: 续写得好不等于会回答问题。
2. tokenization 耦合: 不同 tokenizer 之间的 perplexity 不可直接比较——分词越细, PPL 越低, 但这不代表模型更强。
3. 归一化口径不一: 按 token 平均还是按字符平均, 结论可能相反。

为了绕开这些, 人们发明了“长得像 perplexity 但不是”的指标——cloze (完形) 任务: 挖掉句中某个词, 看模型能否用条件概率复原它。这把“续写”改造成“填空”, 更贴近能力评测。

cloze 准确率只看模型在关键空白处是否把最高概率分配给正确答案:

$$a_{\text{cloze}} = \mathbb{1} \left[\arg \max_{w \in V} P_{\theta}(w \mid \text{context}) = w^* \right]$$

- V : 词表; w^* : 被挖掉的真实词
- $\arg \max_w P_{\theta}(w \mid \text{context})$: 模型在给定上下文下最可能的填词
- 与 perplexity 不同, 这里只关心排名第一是否正确, 而非整段概率——更贴近“会不会”而非“续得顺不顺”

$$P_{\theta}(\text{blank} \mid \text{context}) \quad \text{vs.} \quad P_{\theta}(\text{full sequence})$$

- 左式: cloze 形式, 只评估关键位置的条件概率, 更聚焦
- 右式: 全序列 perplexity, 对所有位置一视同仁
- cloze 把“评估什么”从“整段续写”聚焦到“特定决策点”, 更接近下游能力

4 知识型 Benchmark: MMLU 家族

4.1 MMLU 是什么




Figure 12: MMLU: 57 个学科、近 1.6 万道多项选择题的知识 benchmark¹²

MMLU (Massive Multitask Language Understanding) 是最有影响力的知识型 benchmark: 57 个学科 (从初等数学到专业医学、法律)、每题 4 选 1。它把“模型懂多少世界知识”压缩成一个准确率数字。

评测时的标准做法是少样本提示 (few-shot): 先给模型几道带答案的例题“教它格式”, 再让它答新题。




Figure 13: Few-shot prompt 模板: 用例题示范输出格式, 再让模型作答¹³

¹² 视频画面时间区间: 00:32:45 – 00:33:15。

4.2 Few-shot 的方差陷阱




Figure 14: Few-shot 示例的选择与顺序会带来巨大的指标方差¹⁴

Percy 强调一个常被忽视的事实：选哪几道例题、按什么顺序放，都会显著改变 MMLU 分数。同一个模型，换一组 few-shot 例子，分数可能波动好几个点。

被低估的方差源

few-shot 例子的内容、顺序、数量都是超参。论文里报一个漂亮数字，往往是最优 few-shot 配置下的“上限”。换配置重跑，分数就变。这让跨论文的 MMLU 比较变得很脆弱。

形式化地，设模型在 prompt 模板 s （含特定 few-shot 配置）下的准确率为 $a(s)$ ，跨配置的标准差反映这一方差源：

$$\text{Var}_s[a(s)] = \mathbb{E}_s \left[(a(s) - \bar{a})^2 \right], \quad \bar{a} = \mathbb{E}_s[a(s)]$$

- s ：某种 few-shot 配置（例子的选择与顺序）
- $a(s)$ ：该配置下模型在 benchmark 上的准确率
- $\text{Var}_s[a(s)]$ ：跨配置方差，越大说明分数越依赖具体配置，越不可靠

不过 Percy 也补充：对现代指令模型而言，few-shot 主要是在指定任务格式——模型已经知道怎么答题，例子只是“说明书”。指令越强，对例子的依赖越弱。

¹³视频画面时间区间：00:34:25 – 00:34:55。

¹⁴视频画面时间区间：00:37:25 – 00:37:55。

4.3 MMLU 的时代错位




Figure 15: MMLU 始于 2020 年——那时还没有指令模型，它是为 base model 设计的¹⁵

MMLU 的设计前提已过时

MMLU 创立于 2020 年，彼时没有指令模型。它的 few-shot 形式是为评测 base model 设计的。今天用指令模型去刷它，某种意义上是“用错时代的工具考错时代的卷”。

这就引出了 MMLU 的饱和问题：随着模型变强，MMLU 分数集体逼近 90%+，区分度消失。社区的反应是造更难版本。

¹⁵视频画面时间区间：00:40:15 – 00:40:45。

4.4 MMLU-Pro 与更难的变体




Figure 16: MMLU-Pro: 剔除噪声题、扩到 10 选项，把饱和区重新拉开¹⁶

MMLU-Pro 的做法：删除原 MMLU 中嘈杂、平庸的简单题，把选项从 4 个扩到 10 个（大幅降低蒙对概率），重新拉开区分度。

随机蒙对的期望准确率随选项数 K 下降，使饱和天花板变高：

$$a_{\text{random}} = \frac{1}{K}, \quad a_{\text{ceiling}} \approx 1 - \frac{1}{K}$$

- K ：每题的选项数（MMLU 为 4，MMLU-Pro 为 10）
- a_{random} ：纯随机蒙对的期望准确率—— $K = 4$ 时 0.25， $K = 10$ 时 0.10
- a_{ceiling} ：可区分的有效天花板——选项越多，越能拉开“真懂”与“蒙对”的差距

¹⁶ 视频画面时间区间：00:41:45 – 00:42:15。

Model	COT correct	Observed inference time (s)	# eval
o3 (2025-04-16)	0.753	48.024	446
Gemini 2.5 Pro (03-25 preview)	0.749	43.194	446
o4-mini (2025-04-16)	0.735	22.412	446
Grok 3 mini Beta	0.675	14.215	446
GPT-4.1 (2025-04-14)	0.659	9.906	446
Llama 4 Maverick			446

Stanford

https://crfm.stanford.edu/helm/capabilities/latest/#/runs?q=openai_o3-2025-04-16

Figure 17: GPQA Diamond: 研究生水平的专家级问题，人类博士也只能答对约 65%¹⁷

GPQA (Google-Proof Q&A) 更进一步：由领域专家出题，难度达到研究生水平，即便给人类专家 Google 检索也答不全对。它专门为对抗“模型靠检索/记忆蒙混”而设计。Percy 提到，最近一年 o3 已把 GPQA 推到 75%。

[Phan+ 2025]

2500 questions: multimodal, many subjects, multiple-choice + short-answer

Classics

Question:

Here is a representation of a Roman inscription, originally found on a tombstone. Provide a translation for the Palmyrene script.
A transliteration of the text is provided: RGYN> BT HRY BR <T> HBL

Henry T
Merton College, Oxford

Ecology

Question:

Hummingbirds within Apodiformes uniquely have a bilaterally paired oval bone, a sesamoid embedded in the caudolateral portion of the expanded, cruciate aponeurosis of insertion of m. depressor caudae. How many paired tendons are supported by this sesamoid bone? Answer with a number.

Edward V
Massachusetts Institute of Technology

Mathematics

Question:

The set of natural transformations between two functors

Computer Science

Question:

Let G be a graph. An edge-indicator of G is a function $a: \{0, 1\} \rightarrow$

Stanford

Figure 18: Humanity’s Last Exam: 向全球征集的极致难题集¹⁸

Humanity’s Last Exam (HLE) 则是另一个极端：向全球开放征集“最难”的题，每题都需专家多轮审校。Percy 直言这类数据集的创建极其耗时，且设计哲学几乎与他从第一性原理出发的设计相反——开放征集天然引入偏见。它们“确实很难”，但不代表任何现实分布。

¹⁷ 视频画面时间区间：00:44:25 – 00:44:55。

¹⁸ 视频画面时间区间：00:49:15 – 00:49:45。

难题集的两难

难题集解决了“饱和”问题，却引入了代表性问题：满纸精英级偏题，与普通人、普通场景脱节。“难”不等于“有用”。这正是评估永恒的张力——区分度 vs 真实性。

5 开放生成与人类偏好

5.1 核心难题：开放生成怎么评

开放生成的评估困境

“写一个关于 Stanford 的好故事”——没有标准答案。exact match 失效，F1 失效。怎么把“好不好”变成一个数字？这是整个评估领域最难、也最实际的问题。

Percy 介绍了几条主要路线。

5.2 Chatbot Arena：众包偏好与 Elo

179

180

181

182

183

184

- Random person from the Internet types in prompt
- They get response from two random (anonymized) models
- They rate which one is better
- ELO scores are computed based on the pairwise comparisons

Features: live (not static) inputs, can accomodate new models

Rank* (UB)	Rank (StyleCtrl)	Model	Arena Score	95% CI	Votes	Organization
1	1	Gemini-2.5-Pro-Preview-05-06	1448	+7/-12	3545	Google
1	1	Gemini-2.5-Pro-Exp-03-25	1437	+6/-4	12720	Google
3	1	o3-2025-04-16	1411	+11/-7	5844	OpenAI
3	3	ChatGPT-4o-latest (2025-03-26)	1408	+6/-5	10286	OpenAI
3	6	Grok-3-Preview-02-24	1402	+5/-4	14843	xAI
5	4	GPT-4.5-Preview	1398	+4/-5	15281	OpenAI
5	6	Gemini-2.5-Flash-Preview-04-17	1394	+9/-8	5393	Google
8	14	Gemini-2.0-Flash-Thinking-Exp-01-21	1380	+4/-3	26892	Google
8	7	Gemini-2.0-Pro-Exp-02-05	1380	+4/-4	20421	Google
8	7	DeepSeek-V3-0324	1372	+6/-6	8213	DeepSeek

Figure 19: Chatbot Arena：用户与两个匿名模型对话，表达成对偏好，汇总成 Elo 排名¹⁹

Chatbot Arena (LMSYS) 是最流行的人类评估：用户同时与两个匿名模型对话，选出更喜欢的那个，这些成对偏好用 Elo 评分系统（国际象棋同款）聚合成全局排名。它的优点是持续刷新（总有新数据和新模型），能容纳开放生成。

Elo 的核心更新规则：设模型 A 当前评分 R_A 、模型 B 为 R_B ，A 的期望胜率（被偏好概率）为

$$E_A = \frac{1}{1 + 10^{(R_B - R_A)/400}}$$

- E_A ：模型 A 的期望得分（介于 0、1）
- R_A, R_B ：双方当前 Elo 评分
- 400：标尺常数，表示评分差 400 时强方期望胜率约 0.91

¹⁹视频画面时间区间：00:53:55 – 00:54:25。

每场对局后按实际结果 $S_A \in \{0, 0.5, 1\}$ 更新：

$$R'_A = R_A + K(S_A - E_A)$$

- S_A ：A 的实际结果（胜 1、平 0.5、负 0）
- K ：更新步长，越大则单场影响越大
- 评分差最终反映“被偏好的稳定程度”

这一期望胜率公式源自 **Bradley-Terry 模型**：把“被偏好”建模成评分差的 logistic。若用强度参数 λ_A 替代评分 ($R_A = 400 \log_{10} \lambda_A$)，A 胜 B 的概率即正比于强度比：

$$\Pr(A \succ B) = \frac{\lambda_A}{\lambda_A + \lambda_B}$$

- λ_A, λ_B ：A、B 的潜在“实力”强度参数
- $\Pr(A \succ B)$ ：在成对比较中 A 被偏好的概率
- 这个模型是 Elo、Chatbot Arena 排名、以及很多成对偏好评估的共同数学基础

Chatbot Arena 的问题

- 长度偏好：人类倾向更喜欢更长的回答，于是模型学会注水。
- 风格偏好：格式、语气、排版（emoji、列表）干扰判断。
- 众包质量：用户的偏好未必专业，可能被表面质量蒙蔽。
- 可被 PR 化：厂商把高排名当营销素材，于是 Goodhart 效应再次降临。

5.3 IFEval：指令遵循的可验证测试




Figure 20: IFEval：用可程序化验证的指令（“写一段恰好 10 个词的故事”）测指令遵循²⁰

IFEval 走另一条路：构造可被代码自动验证的指令，比如“写一段恰好 10 个词的故事”——评分就是词数是否等于 10。它窄而精确，不评“故事好不好”，只评“约束是否被满足”。这类功能测试（functional test）回避了主观判断，可复现、可自动化。

²⁰ 视频画面时间区间：00:56:55 – 00:57:25。

5.4 AlpacaEval / WildBench: LLM-as-judge

Rank	Model Name	LC Win Rate	Win Rate
1	GPT-4 Omni (05/13)	57.5%	51.3%
2	GPT-4 Turbo (04/09)	55.0%	46.1%
3	Yi-Large Preview	51.9%	57.5%
4	GPT-4o Mini (07/18)	50.7%	44.7%
5	GPT-4 Preview (11/06)	50.0%	50.0%
6	Claude 3 Opus (02/29)	40.5%	29.1%
7	Llama 3.1 405B Instruct	39.3%	39.1%
8	GPT-4	38.1%	23.6%
9	Quora 72B Instruct	38.1%	30.0%

Figure 21: AlpacaEval: 用一个 LLM（如 GPT-4）当裁判，计算被测模型相对基线的胜率²¹

AlpacaEval 直接拥抱“LLM 当裁判”：让一个强模型（如 GPT-4）评判被测模型的回答是否优于某个固定基线，输出一个胜率（win rate）。这把开放生成评估自动化了。

胜率定义为被测模型 M 在裁判 J 眼中胜过基线 B 的比例：

$$\text{WR}(M) = \Pr_{q \sim Q} [J(q, M) \succ J(q, B)]$$

- Q : 题源分布； M : 被测模型； B : 固定基线（如 text-davinci-003）
- $J(q, \cdot)$: 裁判模型对题 q 的某模型回答的偏好排序
- $\succ$: 表示“被偏好”； $\text{WR} \in [0, 1]$

LLM-as-judge 的偏见

让 GPT-4 评判“模型 A 的回答 vs GPT-4 自己的回答”——它天然偏爱自己的风格（self-preference）。这是已知且不可避免的偏见。此外还有长度偏见、位置偏见（先呈现的更易被选）。

Percy 讲了个趣闻：AlpacaEval 最初没做长度修正，结果模型靠写长文刷分；后来加了长度修正变体才缓解。WildBench 则用真实人机对话作为题源，同样用 LLM 裁判。

评估的评估

AlpacaEval 这类自动指标，其“好坏”本身需要被评估——而公认的判据是：它与 Chatbot Arena 的相关性有多高。于是出现了“用人类偏好校准自动裁判”的元评估循环。能复现、自动、还与人类一致，就是好自动指标。

²¹ 视频画面时间区间：00:58:45 – 00:59:15。

6 Agent 与系统级评估

6.1 为什么需要 agent benchmark




Figure 22: SWE-bench: 给定代码库 + GitHub issue, agent 须提交能通过测试的 PR²²

很多真实任务需要工具调用（运行代码、联网、用计算器）和跨步骤迭代——写一个项目、修一个 bug，都不是一轮对话能完成的。Agent = 语言模型 + 工具 + 循环编排。这就把评估对象从“模型”上升到了“系统”。

SWE-bench 是代表性的 agent benchmark：给定一个真实代码库和一条 GitHub issue 描述，agent 要理解问题、定位代码、修改并提交 PR；评测标准是 PR 是否能让仓库的隐藏测试通过。它把“修 bug”这个真实软件工程任务变成了可自动判分的评测。

设任务集为 $\{(r_i, t_i)\}_{i=1}^N$ （仓库 r_i 与隐藏测试 t_i ），agent A 提交的补丁为 Δ_i ，解决率（resolved rate）为：

$$\text{ResolveRate}(A) = \frac{1}{N} \sum_{i=1}^N \mathbb{I}[t_i(r_i \oplus \Delta_i) = \text{pass}]$$

- $r_i \oplus \Delta_i$ ：仓库 r_i 应用了 agent 补丁 Δ_i 后的状态
- $t_i(\cdot) = \text{pass}$ ：隐藏测试套件全部通过
- $\mathbb{I}[\cdot]$ ：指示函数，任务解决记 1 否则 0
- 这个指标完全可自动化、可复现，无需人类介入判分

SWE-bench 的设计哲学

用真实仓库的真实 issue 作为题源，用既有测试套件作为判分器——既保证真实性，又保证可自动验证。这是 agent benchmark 的黄金范式。

Percy 还提到 MLE-bench：75 场 Kaggle 竞赛，agent 拿到数据集描述要复现出能上榜的方案。这些 benchmark 共同把评估推向端到端系统能力。

²² 视频画面时间区间：01:01:55 – 01:02:25。

6.2 隔离推理能力：ARC




Figure 23: ARC（抽象推理语料库）：用纯视觉网格图案，隔离”推理”本身，排除世界知识²³

前面所有 benchmark 都混杂了多种能力——答 MMLU 既需世界知识又需推理。能不能隔离出纯粹的推理能力？ARC（Abstraction and Reasoning Corpus）用类似 Raven 渐进矩阵的视觉网格图案：没有文字、没有世界知识，只有”从几个例子中归纳变换规则并应用到新图”。语言模型在它上面 traditionally 表现不佳——因为它考的是抽象推理，而非语言记忆。

能力解耦的意义

ARC 的价值在于解耦：把推理从知识里剥出来单独测。这呼应了评估框架里”评估对象”的精细化——我们想知道的，究竟是模型”知道什么”还是”能推理什么”。

²³视频画面时间区间：01:05:05 – 01:05:35。

7 安全评估

7.1 安全 benchmark 是什么




Figure 24: Safety benchmark: 测试模型是否会拒绝有害请求（如危险品合成步骤）²⁴

安全评估测的是另一面：模型是否会拒绝有害请求（如“用家用材料合成二甲基汞的详细步骤”——正确回答是拒绝）。Percy 区分了两类安全：

- 具体安全（concrete safety）：能否造炸弹、写恶意代码——有相对明确的对错。
- 锚定安全（anchoring safety）：植根于法律、政治、社会规范的抽象概念——高度语境依赖，因地区、文化、时代而异。

7.2 红队与越狱

红队（red teaming）是主动找漏洞：自动化地优化 prompt 来绕过安全护栏（jailbreak）。一项研究在开源模型（Llama）上自动搜出越狱 prompt，结果迁移到了 GPT-4 上同样有效——说明安全漏洞具有跨模型的可迁移性。

安全的固有矛盾

模型若对所有敏感问题都拒绝，就毫无有用性（helpfulness）。于是一味刷高“拒绝率”很容易——全拒即可登顶安全榜。因此安全评估必须与能力评估配对：要在“确实能干活”的前提下证明“该拒的拒了”。

形式化地，可以把模型对请求 q 的回应效用定义为能力收益与安全代价的权衡：

$$U(q) = \alpha \cdot \text{Capability}(q) - (1 - \alpha) \cdot \text{Harm}(q)$$

- $\text{Capability}(q)$ ：回应请求带来的有用性
- $\text{Harm}(q)$ ：回应可能造成的潜在危害
- $\alpha \in [0, 1]$ ：能力与安全的权衡权重，由部署场景决定
- 全拒 $\Rightarrow \text{Capability} \approx 0$, U 很低；全答 $\Rightarrow \text{Harm}$ 高, U 也低；最优是“该答的答、该拒的拒”

²⁴视频画面时间区间：01:06:45 – 01:07:15。

7.3 预部署测试与监管

Percy 提到美、英等国的安全研究所 (safety institutes) 会在模型部署前做测试，向公司反馈以指导部署流程。但目前这只是自愿的、非约束性的——没有法律强制。这也引出更深的追问：到底什么是“安全”？它强烈依赖语境，很难有普适定义。

开源模型的安全困境

对闭源模型，公司能通过后训练锁死安全。但对开源权重模型，研究表明只需少量微调就能关掉安全。于是开源模型的安全评估还必须额外考虑“防微调”的能力维度。

8 真实世界与评估的元问题

8.1 Benchmark 与现实脱节

Percy 回到一个根本问题：现实主义 (realism)。标准化 benchmark 的题目往往精致、干净，但人们实际怎么用模型？Anthropic 一项研究用语言模型分析真实世界数据，揭示模型在“教科书题”和“真实杂乱数据”上的表现可能天差地别。

MedHELM 是这方面的尝试：此前的医学 benchmark 多基于标准化考试题，而 MedHELM 用真实临床场景评测，部分数据涉及患者隐私，因此不公开托管。

考试题 vs 真实场景

标准化考题追求“干净可判分”，却可能完全不代表真实工作流。一个在 USMLE 上高分的模型，未必在真实临床决策里有用。评估的外部效度 (ecological validity) 常被忽视。

8.2 污染检测与标注噪声




Figure 25: 数据集创建极其耗时：出题人拟题、专家校验、反馈多轮——但即便如此也未必无错²⁵

污染检测有两条路线：

1. 统计侦测：若模型对题目的回答呈现出与该题在数据集中位置顺序强相关的偏好，就是被训练过的信号。

²⁵ 视频画面时间区间：01:18:35 – 01:19:05。

2. 规范社区：一项研究发现，模型提供方在发布时是否真的检查了测试集不在训练集里——有些做，但远非行业惯例。Percy 主张建立规范：报分数时，必须同时报你去污染的检查。

统计侦测的一个经典信号是记忆化（memorization）：若测试样本 x 被纳入训练集，模型对其分配的概率会异常高，可用似然比检验：

$$\Lambda(x) = \frac{P_{\theta}(x)}{P_{\text{ref}}(x)}$$

- $P_{\theta}(x)$ ：被检模型对样本 x 的似然
- $P_{\text{ref}}(x)$ ：未在 x 上训练的参考模型的似然
- $\Lambda(x) \gg 1$ ：似然比远大于 1，强烈提示 x 已被记忆（污染）

被低估的标注噪声

SWE-bench 曾被发现有标注错误，修正后分数才上升。MATH、GSM8K 这些“看着难、都考 90%+”的 benchmark，相当一部分“难题”其实是标注噪声——题目本身有问题。修掉噪声后，真实难度下降，分数自然抬高。你看到的 95% 也许部分是虚的。

设观测准确率 $\hat{a}$ 、真实准确率 a 、标注错误率 η ，则两者关系为：

$$\hat{a} = (1 - \eta)a + \eta(1 - a)$$

- η ：标注答案被标错的概率（噪声率）
- 第一项 $(1 - \eta)a$ ：模型答对且标注也对的情形
- 第二项 $\eta(1 - a)$ ：模型答错却因标注错而“被判对”的情形
- 当 η 不可忽略时， $\hat{a}$ 会系统性偏离 a ——高分里掺了噪声的水分

8.3 方法 vs 模型：评估对象的回归

Percy 在结尾回到一个常被混淆的问题。在严格的科研语境里，论文的产出是一个新方法（新架构、新训练算法），模型只是该方法的一个实例。但如今人们常把“模型分数”当成“方法好坏”——没有清晰的对照（如固定算力、固定数据、只换方法），这种归因是无效的。

对照实验的必要性

要让一个 benchmark 数字有意义地支持“方法 A 比方法 B 好”，必须有严格的受控对照：固定训练数据、算力、超参搜索预算，只切换方法本身。否则分数差异可能来自数据、算力、调参运气的任意组合——方法本身反而无法被分离。

这可以用一个简单的线性模型理解。设观测到的指标 Y 由多因素决定：

$$Y = \beta_M M + \beta_D D + \beta_C C + \beta_H H + \varepsilon$$

- M ：方法的贡献； D ：数据； C ：算力； H ：超参调优
- β ：各因素的系数（敏感度）
- ε ：随机噪声（种子、实现细节）
- 若不做对照， D, C, H 与 M 混杂（confounded）， β_M 无法被识别——你无法声称“方法”带来了提升

8.4 竞赛式评估的启示

Percy 最后提到几类竞赛式评估：speedrun competition（固定数据集，比拼达到特定 loss 的时间）、datacomp（比拼数据选择策略以达到某精度）。它们通过明确定义游戏规则来鼓励算法创新，对研究者友好。但他强调：评估系统对用户也有巨大价值——规则清晰、目标明确，才谈得上比较。

9 总结

9.1 核心论点

六个核心论点

1. 没有唯一正确的评估：评估好坏取决于它是否回答了你的真实问题。脱离目标谈分数毫无意义。
2. Perplexity 是起点不是终点：它信息量大但对指令、对齐、安全不敏感，且与 tokenizer 耦合，跨模型不可直接比。
3. Benchmark 在饱和与被博弈间挣扎：MMLU 家族通过加难（Pro、GPQA、HLE）对抗饱和，但难题集牺牲了代表性。
4. 开放生成靠偏好与裁判：Chatbot Arena（人类 Elo）与 AlpacaEval/WildBench（LLM-as-judge）各有偏见，需用相关性相互校准。
5. Agent benchmark 把评估推向系统级：SWE-bench、MLE-bench 用真实任务 + 自动判分，端到端测系统能力。
6. 安全必须与能力配对评估：全拒即可“安全”，所以安全榜只在与能力榜并置时才有意义。

9.2 贯穿始终的主线

Goodhart 定律：评估永恒的阴影

一旦一个指标被当成目标去优化，它就不再是好指标。MMLU 被饱和、Chatbot Arena 被长度博弈、安全榜被“全拒”刷分——每个评估方法诞生之日，就开始走向失效。评估不是一个一次性工程，而是需要持续刷新、持续去污染、持续与真实使用对齐的长期事业。这是 Percy 留给整堂课最深的告诫。

9.3 评估清单：动手前问自己

设计评估时的检查清单

1. 目标：我要回答的到底是哪个问题？（采购？科研？合规？开发反馈？）
2. 对象：评的是模型、系统、还是方法？需要什么对照？
3. 输入：prompt 从哪来？是否适配模型？有没有尾部困难样本？
4. 调用：零样本/少样本/CoT？是否允许工具？这些引入了多少方差？
5. 输出：参考答案干净吗？开放生成怎么判？成本是否计入？
6. 解读：分数够上线吗？是否被污染？是否只是噪声？
7. 对齐：这个 benchmark 与真实使用场景相关吗？外部效度如何？

9.4 配套阅读

以下是与本讲直接相关的关键资源，建议按主题深入：

资源	对应知识点
HELM (Stanford)	统一评估框架与多维度排行榜
MMLU / MMLU-Pro (Hendrycks 等)	知识型 benchmark 与饱和
GPQA (Rein 等 2023)	研究生级专家问题
Chatbot Arena (LMSYS)	众包偏好与 Elo 排名
AlpacaEval (Dubois 等 2023)	LLM-as-judge 自动胜率
SWE-bench (Jimenez 等 2024)	Agent 端到端代码任务
ARC (Chollet 2019)	抽象推理与能力解耦
Goodhart's Law	评估与博弈的根本张力